الجمهورية الجزائرية الديمقراطية الشعبية
ⵜⴰⴷⵣⴰⵢⵔ ⵜⴰⵎⵣⵡⴰⵔⵜ ⵜⴰⵎⴰⵡⴰⵙⵜ ⵜⴰⵏⵏⵓⵔⵜ
République Algérienne Démocratique et Populaire
وزارة التعليم العالي والبحث العلمي
ⴰⵢⵏⴷⵉ ⵏ ⵓⵙⵙⵍⵎⴷ ⵓⵏⴰⵎⵓⵔ ⴷ ⵓⵔⵣⵣⵓ ⵓⵙⵙⵍⵎⴷ
Ministère de l'Enseignement Supérieur et de la Recherche Scientifique

ECOLE NATIONALE SUPÉRIEURE D'INFORMATIQUE

المدرسة الوطنية العليا للإعلام الآلي
ⴰⵢⵏⵓⵎⴰⵙ ⴰⵢⵏⵏⵍⵍⵉ ⵏ ⵜⵓⵏⵏⵓⵏⵏⵉⵜ
École nationale Supérieure d'Informatique

Rapport de stage (SPE)

2ème année Cycle Supérieur (2CS)

Option : Systèmes Intelligents et Données (SD)

Thème :

Unification intelligente des référentiels produits à partir de désignations hétérogènes

Réalisé par :

Merabtine Aya Malek

Encadré par :

Mme.Bouchoul Bouchra

Organisme d'accueil : NAFTAL-SPA

Promotion : 2025 – 2026

REMERCIEMENTS

Tout d'abord, je tiens à exprimer ma profonde gratitude à Allah, qui m'a accordé la persévérance et la guidance nécessaires pour mener à bien ce stage. Sa grâce infinie a été ma source d'inspiration et de force.

Je souhaite exprimer mes remerciements les plus sincères à toute l'équipe de la société NAFTAL pour m'avoir accueillie chaleureusement et pour leur accompagnement tout au long de cette expérience professionnelle.

Mes remerciements particuliers vont à Monsieur B.MEKAOUI, directeur de la Direction Centrale des Systèmes d'Information (DCSI), pour son soutien et l'intérêt qu'il a porté à mon travail durant ce stage.

Je souhaite également exprimer ma profonde reconnaissance à mon encadrante Madame B.BOUCHOUL pour sa confiance, son soutien et ses orientations bienveillantes tout au long de ce stage.

Leur disponibilité, leurs conseils avisés et leur volonté de partager leurs connaissances ont grandement facilité ma découverte de l'environnement technologique et ont rendu ce stage particulièrement enrichissant.

Enfin, j'adresse mes remerciements chaleureux à l'ensemble du personnel de NAFTAL pour leur accueil, leur soutien constant et leurs encouragements. Je suis reconnaissante d'avoir pu bénéficier de leur expertise et de leur accompagnement, qui ont largement contribué à la réussite de ce stage.

Résumé

Dans le cadre du stage pratique en entreprise (SPE) de l'École Nationale Supérieure d'Informatique (ESI), ce stage a été réalisé au sein de la Direction Centrale des Systèmes d'Information de NAFTAL. L'objectif principal était de concevoir une solution intelligente pour unifier les référentiels produits issus de désignations hétérogènes, afin d'améliorer la qualité et la cohérence des données dans les différents systèmes d'information.

L'analyse des processus métiers a révélé des limites majeures : duplication et incohérence des données, difficultés d'intégration entre applications, charges de maintenance élevées et absence de vue consolidée des produits. Pour y remédier, une méthodologie combinant traitement automatique du langage naturel (NLP) et intelligence artificielle générative a été mise en œuvre, permettant d'extraire les informations clés, de regrouper les produits similaires et de les classer selon une hiérarchie standardisée.

Le rapport présente l'entreprise NAFTAL et son environnement technologique, détaille l'analyse des besoins et des désignations hétérogènes, expose la méthodologie adoptée, les technologies utilisées et les résultats obtenus, avant de conclure par des perspectives d'amélioration.

Mots-clés :
Unification des référentiels, Désignations hétérogènes, NLP, IA générative, Classification hiérarchique.

Table des matières

Remerciements **i**

Résumé **ii**

Introduction générale **1**

1 Chapitre 01 : Étude de l'existant **2**
1.1 Introduction 2
1.2 Présentation de l'organisme d'acceuil 2
1.2.1 Historique 3
1.2.2 Secteur d'activité de NAFTAL 3
1.2.3 Missions stratégiques de NAFTAL 4
1.2.4 Structure et organisation de l'entreprise 4
1.2.5 Produits et services de NAFTAL 6
1.2.6 Clients et fournisseurs 7
1.2.7 Position sur le marché 8
1.3 Solutions digitales au service de la clientèle 8
1.4 Analyse de l'existant 9
1.4.1 Présentation du référentiel d'entreprise 9
1.4.2 Étude du système existant 10
1.4.3 Diagnostique 12
1.5 Conclusion 13

2 Chapitre 02 : État de l'art **14**
2.1 Introduction 14
2.2 Modèles de langage : définitions et principes généraux 14
2.2.1 Modèles de langage. 14
2.2.2 Large Language Models (LLMs). 15
2.2.3 L'architecture Transformer 15
2.2.4 Limites opérationnelles des API de modèles de langage 18
2.2.5 Approches existantes 18
2.3 Conclusion 19

3 Chapitre 03 : Conception **20**
3.1 Introduction 20
3.2 Expression des besoins et spécifications 20
3.2.1 Expression des besoins 20
3.2.2 Spécifications fonctionnelles 20
3.2.3 Spécifications techniques 21

3.3 Architecture adoptée . . . 21
3.4 Collecte des données . . . 22
3.4.1 Sources internes . . . 22
3.4.2 Sources externes . . . 22
3.5 Prétraitement des données . . . 23
3.5.1 Sélection des variables pertinentes . . . 23
3.5.2 Groupement des jeux de données . . . 23
3.5.3 Normalisation des désignations . . . 23
3.6 Classification hiérarchique . . . 24
3.6.1 Modèle retenu et justification . . . 24
3.6.2 Traitement par lots . . . 25
3.6.3 Parallélisme via multithreading . . . 25
3.6.4 Processus de validation . . . 25
3.7 Codification . . . 25
3.8 Alignement des codes produits . . . 26
3.8.1 Modèle entité-association . . . 26
3.8.2 Modèle relationnel . . . 26
3.9 Conclusion . . . 26

4 Chapitre 04 : Implémentation 27
4.1 Introduction . . . 27
4.2 Environnement technique adopté . . . 27
4.2.1 Langage de programmation . . . 27
4.2.2 Bibliothèques Python . . . 27
4.2.3 Services et API externes . . . 28
4.3 Interface Utilisateur . . . 29
4.3.1 Structure générale de l'application . . . 29
4.3.2 Page d'accueil . . . 30
4.3.3 Page des pièces de rechange . . . 31
4.4 Conclusion . . . 31

5 Chapitre 05 : Évaluation 32
5.1 Introduction . . . 32
5.2 Évaluation fonctionnelle . . . 32
5.2.1 Évaluation fonctionnelle . . . 32
5.3 Évalution technique des performances . . . 33
5.3.1 Temps d'exécution . . . 33
5.3.2 Scalabilité . . . 33
5.3.3 Robustesse et fiabilité . . . 34
5.3.4 Considérations techniques globales . . . 34
5.4 Évaluation ergonomique . . . 34
5.4.1 Résultats obtenus . . . 35
5.4.2 Analyse des résultats . . . 35
5.5 Analyse critique et perspectives . . . 35
5.6 Conclusion . . . 36

Conclusion générale 37

Références 40

Liste des figures

1.1 Logo de l'entreprise NAFTAL 2
1.2 Évolution historique de NAFTAL 3
1.3 Structure organisationnelle générale de NAFTAL 5
1.4 Structure organisationnelle de la DCSI 6
1.5 Hiérarchie théorique du référentiel d'entreprise. 9
1.6 Processus métier - gestion des besoins d'achat 11
1.7 Flux de données 12

2.1 Architecture générale du Transformer (extraite de [1]). 17

3.1 Architecture monolithique modulaire de la solution. 22
3.2 Modèle entité–association de l'alignement des produits 26

4.1 Logo de l'application web 29
4.2 Interface de la page d'accueil. 30
4.3 Interface de la page des pièces de rechange. 31

5.1 Résultats des audits PageSpeed Insights pour les deux versions (Mobile et Desktop). 35
2 Performances du modèle Llama 3.3 70B Instruct sur différents benchmarks (source : Vals.ai). 38

Liste des tableaux

1.1 Volumes commercialisés par Naftal en 2023. 8
1.2 Synthèse des contraintes identifiées 13

2.1 Caractéristiques techniques des principales API de modèles de langage. . . 18
2.2 Principales approches existantes pour l'unification des désignations industrielles. 19

3.2 Spécifications fonctionnelles du système avec priorités (MoSCoW) 21
3.3 Statistiques générales sur les jeux de données internes. 22
3.4 Statistiques générales sur les données collectées en source externe. 23

5.2 Évaluation fonctionnelle des spécifications du système 33
3 Caractéristiques principales du modèle Llama 3.3 70B Instruct. 38

Introduction générale

Dans un contexte marqué par la transformation numérique et la multiplication des solutions logicielles, les entreprises modernes s'appuient sur des systèmes d'information de plus en plus complexes pour piloter leurs activités. La capacité à collecter, centraliser et analyser efficacement les données constitue aujourd'hui un facteur stratégique de compétitivité. Dans ce cadre, les référentiels produits occupent une place essentielle puisqu'ils permettent d'assurer la cohérence et la fiabilité des informations au sein des différentes applications et départements.

NAFTAL, filiale du groupe SONATRACH et acteur majeur de la distribution des produits pétroliers en Algérie, s'appuie sur un écosystème riche de systèmes d'information déployés pour couvrir des processus variés : gestion des stocks, maintenance, distribution, commercialisation, finance et ressources humaines. Cependant, chaque système a historiquement développé son propre référentiel produit, ce qui a engendré plusieurs limitations : redondance et incohérence des données, difficultés d'interopérabilité, charges élevées de maintenance et difficulté d'obtenir une vision consolidée et fiable de l'information.

Dans ce contexte, le projet réalisé au sein de la Direction Centrale des Systèmes d'Information (DCSI) vise à concevoir une solution intelligente d'unification des référentiels produits. L'objectif principal est de mettre en place un mécanisme capable d'assainir et normaliser les désignations produits, de regrouper les entrées similaires malgré les variations de saisie, et de classifier chaque produit selon une hiérarchie normalisée : *Famille* → *Sous-famille* → *Agrégat* → *Produit*. Pour atteindre ces objectifs, des technologies avancées de traitement automatique du langage naturel (NLP) et d'intelligence artificielle générative ont été mobilisées.

La structure du rapport s'articule comme suit :

- Le premier chapitre présente l'entreprise NAFTAL et l'état actuel du système d'information.
- Le deuxième chapitre expose l'état de l'art et les approches existantes liées à l'unification des référentiels produits.
- Le troisième chapitre décrit la conception et la méthodologie de la solution proposée.
- Le quatrième chapitre traite de l'implémentation et des résultats obtenus.
- Le cinquième chapitre porte sur l'évaluation fonctionnelle, technique et ergonomique du système.

Chapitre 1

Étude de l'existant

1.1 Introduction

Ce chapitre vise à présenter le cadre organisationnel et opérationnel de NAFTAL. Il propose d'abord une vue d'ensemble de l'entreprise, en mettant en évidence son organisation, ses principales activités et son environnement technologique, afin de situer son fonctionnement global. Il s'attache ensuite à l'étude de l'existant, à travers une analyse du système d'information et des référentiels métiers, en soulignant les pratiques en place ainsi que les limites et incohérences observées. Cette approche permet de cerner avec précision le contexte dans lequel s'inscrit la mission de stage.

1.2 Présentation de l'organisme d'acceuil

Naftal est une société par actions (SPA) au capital social de 160 milliards de dinars algériens (DA). Fondée en 1982, cette entreprise pétrolière algérienne constitue une filiale à 100% du groupe SONATRACH et se spécialise dans les activités commerciales relatives à la distribution et à la commercialisation des produits pétroliers et dérivés sur l'ensemble du territoire national.
L'acronyme NAFTAL est issu de :

- **NAFT** : terme arabe désignant le pétrole.
- **AL** : en référence à l'Algérie.

Le siège social de l'entreprise est implanté à Cheraga, dans la wilaya d'Alger, comme illustré par le logo officiel présenté en figure figure 1.1 ci-dessous.

Figure 1.1 – Logo de l'entreprise NAFTAL

1.2.1 Historique

NAFTAL a connu plusieurs transformations structurelles depuis sa création, reflétant les évolutions économiques et industrielles de l'Algérie. L'histoire de l'entreprise peut se résumer comme suit [3] :

- 6 avril 1981 : Création de l'entreprise ERDP (Entreprise de Raffinage et de Distribution des Produits pétroliers) issue de Sonatrach, par le décret N° 80/101.
- 1er janvier 1982 : L'ERDP prend en charge la gestion de l'industrie du raffinage et la commercialisation/distribution des produits pétroliers.
- 25 août 1987 : Séparation des activités de raffinage et de distribution :
  - NAFTAL : commercialisation et distribution des produits pétroliers (décret N° 87-189).
  - NAFTEC : raffinage des produits pétroliers (décret N° 87-190).
- 18 avril 1998 : NAFTAL devient une société par actions (SPA), filiale à 100% de Sonatrach Valorisation des Hydrocarbures, avec un capital social de 6,65 milliards de DA.
- 21 décembre 1999 : Création de STPE en partenariat avec le SNTF pour le transport des produits énergétiques par voie ferrée.
- 29 juillet 2002 : Augmentation du capital social de NAFTAL de 6,65 à 15,65 milliards de DA.

Aujourd'hui, NAFTAL SPA se positionne comme l'entreprise nationale de commercialisation et distribution des produits pétroliers et dérivés, consolidant sa mission principale et son rôle stratégique sur le marché national.

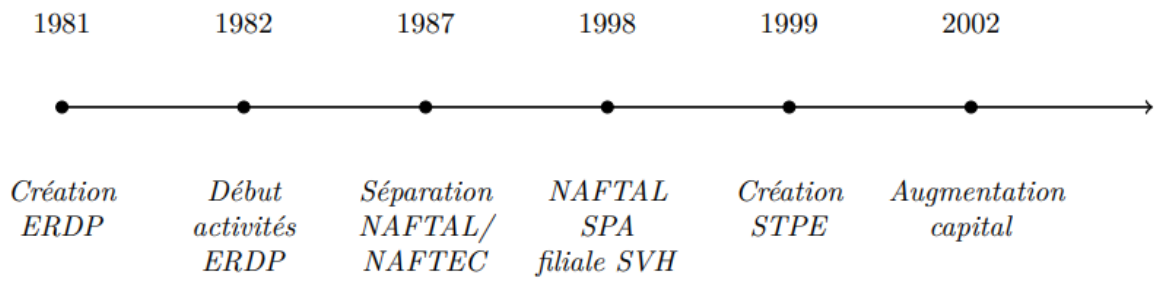

FIGURE 1.2 – Évolution historique de NAFTAL

1.2.2 Secteur d'activité de NAFTAL

NAFTAL-SPA occupe une position stratégique dans le secteur de l'énergie en Algérie, plus précisément dans la commercialisation, le stockage et la distribution des produits pétroliers et dérivés. Ses activités couvrent plusieurs domaines clés [3] :

- L'enfûtage du GPL (gaz de pétrole liquéfié) et la formulation de mélanges de bitume destinés à la construction et à l'industrie.
- La distribution et la commercialisation de carburants, lubrifiants, bitumes, pneumatiques, GPL/carburant et autres produits spécifiques.

- Le transport et l'approvisionnement via différents moyens logistiques : cabotage et pipelines pour les entrepôts, rail pour les dépôts, et route pour la livraison aux clients et dépôts non desservis par le ferroviaire.
- L'organisation par lignes de produits (bitumes, lubrifiants, GPL, pneumatiques, aviation, marine, réseau et logistique) afin d'améliorer l'efficacité et d'assurer une couverture nationale optimale.

1.2.3 Missions stratégiques de NAFTAL

En parallèle de ses activités opérationnelles, NAFTAL définit un ensemble de missions essentielles qui traduisent son rôle et ses responsabilités :

- Assurer la couverture des besoins nationaux en carburants et produits pétroliers.
- Moderniser et optimiser les infrastructures de stockage et de distribution.
- Réaliser des études de marché sur la consommation des produits énergétiques.
- Optimiser l'utilisation des moyens et infrastructures disponibles.
- Développer une stratégie orientée client et une planification à moyen terme pour répondre à la demande croissante, estimée à près de 13,3 millions de tonnes par an.

1.2.4 Structure et organisation de l'entreprise

1.2.4.1 Structure organisationnelle générale de NAFTAL

L'entreprise NAFTAL-SPA adopte une **structure organisationnelle hybride**, combinant :

- une organisation **divisionnelle**, articulée autour de trois branches principales (Carburants, Commercialisation et GPL) qui assurent la gestion opérationnelle des activités.
- et une organisation **fonctionnelle**, reposant sur des directions centrales transversales (Systèmes d'Information, Santé et Sécurité, Qualité, Audit, Communication, etc.) qui soutiennent et coordonnent l'ensemble des opérations.

Cette configuration favorise à la fois l'**autonomie des branches**, pour une meilleure réactivité face aux spécificités de chaque marché, et l'**alignement stratégique global**, assuré par les directions centrales. Elle permet ainsi une gestion optimisée des ressources et une cohérence dans le pilotage des activités.

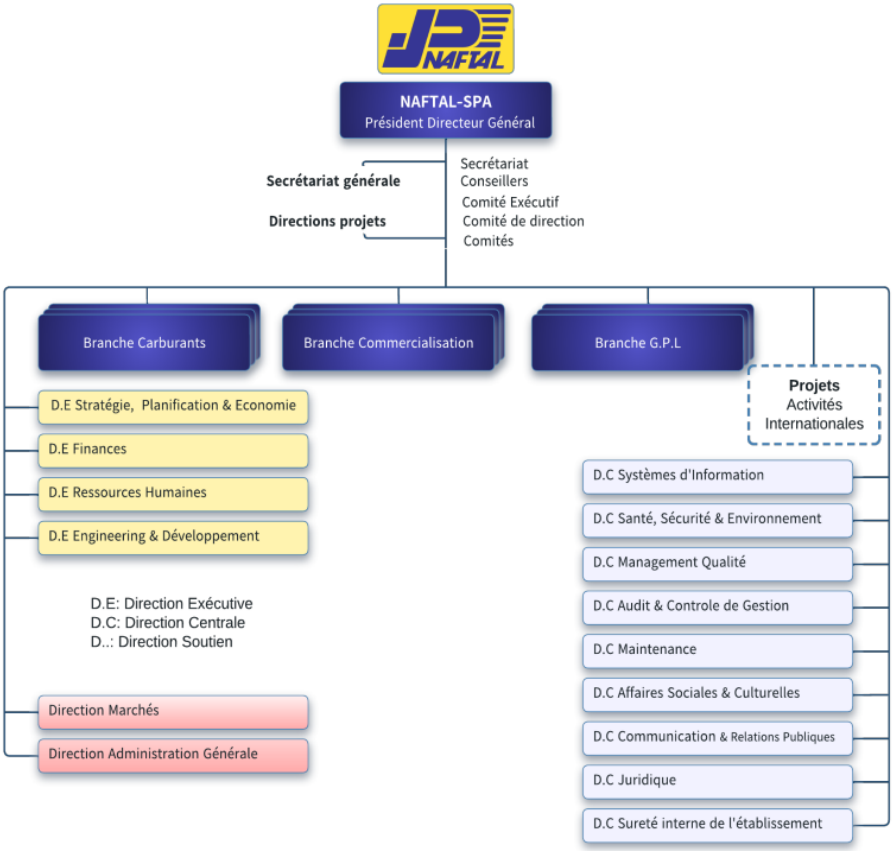

FIGURE 1.3 – Structure organisationnelle générale de NAFTAL

1.2.4.2 Structure organisationnelle de la Direction Centrale des Systèmes d'Information (DCSI)

La Direction Centrale des Systèmes d'Information (DCSI), rattachée à NAFTAL, adopte une structure **hiérarchique**.
Elle est organisée autour de plusieurs directions spécialisées, illustrées dans la figure 1.4 :

- Direction Infrastructures : gestion des réseaux, systèmes d'exploitation et bases de données.
- Direction Opérations : gestion des applications, reporting et Business Intelligence.
- Direction Solutions Métiers : développement et intégration des applications métiers.
- Direction Sécurité : protection des systèmes d'information et conformité réglementaire.
- Direction Informations Documentaires : gestion des archives, des documents stratégiques et de la capitalisation du savoir.

Chaque direction est subdivisée en départements spécialisés. Cette organisation favorise :

- Une clarté dans la répartition des responsabilités,
- Une meilleure coordination entre équipes techniques grâce à une organisation orientée compétences.

C'est au sein de cette direction, et plus précisément au niveau de la Direction Solutions Métiers, dans le Département Architecture, que j'ai effectué mon stage pratique. Cette affectation m'a permis de découvrir le fonctionnement interne de la DCSI et de m'impliquer dans des missions liées à la conception et à l'optimisation des solutions métiers. L'organigramme ci-dessous illustre la hiérarchie et la structure interne de la DCSI.

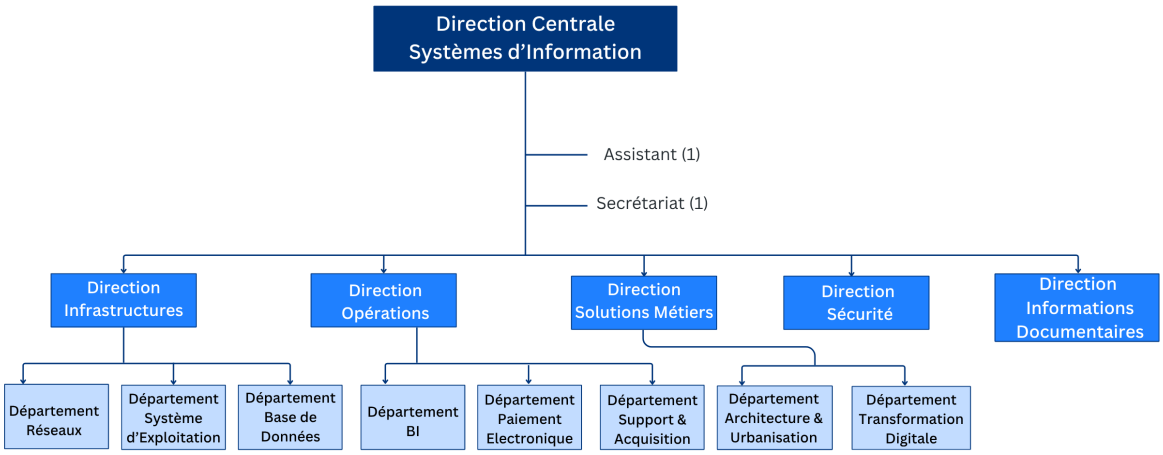

FIGURE 1.4 – Structure organisationnelle de la DCSI

1.2.4.3 Missions de la DCSI

La Direction Centrale des Systèmes d'Information (DCSI) occupe une place stratégique dans la transformation numérique de NAFTAL. Elle veille à l'harmonisation et à la sécurité du système d'information, tout en accompagnant l'évolution technologique. Ses missions principales couvrent :

- l'optimisation et la cohérence de l'environnement informatique,
- l'intégration de progiciels et d'outils d'aide à la décision,
- la migration et la modernisation des systèmes,
- le déploiement de technologies favorisant la collaboration,
- la sécurisation et la résilience du système d'information.

À travers ces actions, la DCSI contribue directement à la modernisation de l'entreprise et au renforcement de ses performances.

1.2.5 Produits et services de NAFTAL

NAFTAL propose une offre diversifiée de produits et services couvrant à la fois les particuliers et les professionnels. Elle occupe une place centrale dans la distribution pétrolière en Algérie, tout en enrichissant son réseau de stations-service par des prestations complémentaires. L'ensemble de son offre se structure autour de trois volets : produits pour particuliers, produits pour professionnels et services associés[3].

1.2.5.1 Produits destinés aux particuliers

L'offre de NAFTAL à destination des consommateurs finaux couvre principalement :

- **Carburants terrestres** : essence sans plomb, gasoil et GPL/carburant, répondant aux normes de qualité exigées.
- **Gaz de Pétrole Liquéfié (GPL)** : commercialisation du butane et du propane, utilisés à la fois dans les foyers et dans certaines applications industrielles.
- **Lubrifiants** : une gamme variée pour automobiles et applications industrielles.
- **Pneumatiques** : distribution de pneus adaptés à différents types de véhicules, allant du tourisme aux poids lourds.
- **Sirghaz** : un mélange de butane et de propane, dont la composition est ajustée en fonction des saisons et des régions.

1.2.5.2 Produits destinés aux professionnels

NAFTAL répond également aux besoins spécifiques des entreprises et des institutions, notamment à travers :

- **Produits pour l'aviation** : carburants spécialisés et lubrifiants pour moteurs d'avions et systèmes hydrauliques.
- **Produits pour la marine** : carburants et lubrifiants adaptés aux moteurs marins.
- **Bitumes** : utilisés dans la construction routière, les travaux d'étanchéité et d'isolation. NAFTAL propose plusieurs types de bitumes, notamment purs et modifiés aux polymères.
- **Produits spéciaux** : une gamme diversifiée comprenant les paraffines, les cires, les solvants et les essences spéciales.

1.2.5.3 Services associés

Au-delà de la distribution de produits, NAFTAL met à la disposition de ses clients un réseau de plus de 2000 stations-service couvrant l'ensemble du territoire national. Ces stations proposent :

- L'approvisionnement en carburants de qualité (essence, gasoil et GPL/C).
- Des services automobiles complémentaires, tels que la vidange, le lavage, le contrôle de la pression des pneus et la vente d'accessoires et produits d'entretien.
- Un programme de modernisation continue visant à optimiser l'expérience client, par le renouvellement esthétique des stations, le perfectionnement du personnel.

1.2.6 Clients et fournisseurs

Naftal entretient un réseau solide et diversifié de clients et de fournisseurs, ce qui lui permet de répondre efficacement aux besoins de différents segments du marché et d'assurer la continuité de ses activités.

Clients :

- Consommateurs finaux : desservis via le réseau de stations-service de l'entreprise, pour l'achat de carburants, de gaz de pétrole liquéfié (GPL), de lubrifiants et autres produits.
- Entreprises et institutions : opérant principalement dans les secteurs de l'énergie, des transports et de la construction, tels que Sonelgaz (électricité et gaz), les compagnies de transport public et des entreprises de construction, qui s'approvisionnent en carburants et autres produits pétroliers.

- Partenaires stratégiques : certaines entreprises publiques et partenaires institutionnels bénéficient également des services de Naftal pour leurs besoins spécifiques, comme la Marine nationale ou les aéroports nationaux.

Fournisseurs :

- Sonatrach : société mère de Naftal, fournisseur principal de pétrole brut et de gaz.
- Fournisseurs locaux : apportent des équipements, des services et des produits complémentaires nécessaires au fonctionnement des stations et à la qualité du service, tels que des entreprises locales de maintenance ou de distribution d'équipements industriels.
- Fournisseurs internationaux : interviennent pour des produits spécifiques ou en cas de besoins ponctuels, par exemple pour l'acquisition de technologies de raffinage ou d'équipements spécialisés provenant de pays européens ou asiatiques.

1.2.7 Position sur le marché

Naftal, filiale de Sonatrach, est le principal acteur de la distribution des carburants, du GPL et des lubrifiants en Algérie. Grâce à son large réseau de stations-service et de centres de distribution, elle assure un approvisionnement national régulier et occupe une position dominante sur le marché. En 2023, son volume de ventes a atteint 16,1 millions de tonnes de produits pétroliers, répartis entre ses différentes activités comme suit :

Produits	**Réalisations**
Carburants terrestres	12,1 millions de tonnes
Carburants aviation	636,4 milliers de tonnes
Carburants marine	333,2 milliers de tonnes
GPL	2,5 millions de tonnes
Bitumes	401,8 milliers de tonnes
Lubrifiants	78,1 milliers de tonnes
Produits spéciaux	5,9 milliers de tonnes
Pneumatiques véhicules	236,4 milliers d'unités

Table 1.1 – Volumes commercialisés par Naftal en 2023.

Ces activités ont généré un chiffre d'affaires de 423,1 milliards de dinars, en progression de 4,57% par rapport à 2022 (404,6 milliards de dinars). Par ailleurs, les dépenses d'investissement ont atteint 23,9 milliards de dinars, témoignant de la capacité de l'entreprise à renforcer ses infrastructures et à diversifier ses services [3].

1.3 Solutions digitales au service de la clientèle

Dans le cadre de sa stratégie de digitalisation et d'amélioration de la relation client, Naftal a développé plusieurs solutions numériques destinées à accompagner ses usagers au quotidien. Ces outils visent principalement à faciliter l'accès aux services, améliorer l'expérience client et renforcer la proximité avec la marque.

Parmi ces solutions figure :

NAFTAL Khadamat

Une application mobile développée en partenariat avec une entreprise spécialisée. Elle illustre la démarche de l'entreprise visant à faciliter l'accès à l'information et à améliorer l'expérience des conducteurs au sein de son réseau de stations-service [4].

MyNaftal

Une plateforme sécurisée destinée aux clients corporate de Naftal, accessible via navigateur web ou application mobile. Elle illustre la démarche de l'entreprise visant à simplifier la gestion des commandes, le suivi des livraisons et l'accès aux factures, tout en offrant un canal direct de communication avec le service client. Cette solution numérique permet ainsi d'améliorer l'expérience des partenaires professionnels et de renforcer la relation entre Naftal et sa clientèle corporate [5].

NAFTAL Card

Une solution numérique pour les clients corporate, permettant le paiement électronique des carburants et le rechargement à distance des cartes. Ce service simplifie la gestion des approvisionnements et s'inscrit dans la stratégie de digitalisation de Naftal, renforçant l'efficacité et la praticité pour ses partenaires professionnels [6].

1.4 Analyse de l'existant

1.4.1 Présentation du référentiel d'entreprise

Au sein de NAFTAL, le référentiel d'entreprise constitue en principe un entrepôt de données structurées, centralisées et unifiées, regroupant l'ensemble des informations de référence nécessaires à la cohérence des opérations. Il inclut notamment la codification des produits, les unités de mesure, les clients, les fournisseurs, les sites, les équipements etc.

Ce référentiel repose sur une hiérarchie normalisée qui permet de classer les produits de manière progressive et cohérente selon quatre niveaux :

$$\textit{Famille} \rightarrow \textit{Sous-famille} \rightarrow \textit{Agrégat} \rightarrow \textit{Produit}$$

Cette structuration hiérarchique garantit, en théorie, une organisation claire des données et facilite leur exploitation par l'ensemble des systèmes d'information de l'entreprise.

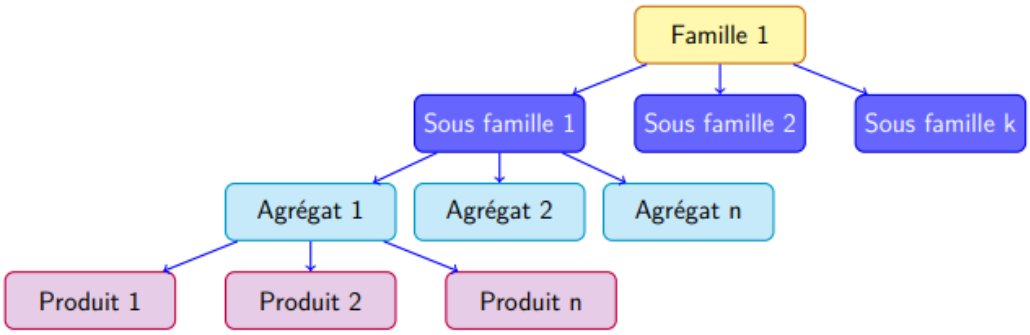

FIGURE 1.5 – Hiérarchie théorique du référentiel d'entreprise.

1.4.2 Étude du système existant

Bien que NAFTAL dispose d'un référentiel d'entreprise centralisé, chaque système métier continue d'utiliser son propre référentiel spécifique. Cette fragmentation engendre des incohérences et limite la fiabilité du référentiel central comme source unique d'information.

1.4.2.1 État actuel des systèmes d'information

Afin d'illustrer les difficultés engendrées par cette fragmentation, deux systèmes d'information peuvent être pris en exemple :

Système des pièces de rechange et installations fixes

Dans ce système, un problème majeur réside dans la codification des produits, qui varie en fonction de **la source d'approvisionnement**. En effet, un produit acquis directement auprès de la maison mère reçoit un code comportant une référence à celle-ci, tandis que le même produit acheté via un fournisseur intermédiaire est enregistré sous un code distinct faisant référence au fournisseur. De plus, les spécifications techniques des produits (version, taille, dimension, couleur...etc) peuvent également influencer la codification, ce qui renforce encore la diversité des codes pour un même article. Cette situation conduit à l'existence de plusieurs codes pour un même article, générant une incohérence dans les données et compliquant considérablement les processus de suivi, de rapprochement et de consolidation des informations.

Système Économat (produits consommables)

Contrairement au référentiel d'entreprise qui repose sur une hiérarchie à quatre niveaux, le système Économat est structuré en trois niveaux (famille, sous-famille et produit). Cependant, chaque combinaison de produit, de marque et de version (ou couleur) y est enregistrée comme un produit distinct. Cette approche complique le rapprochement avec le référentiel global et limite la capacité d'analyse transversale.

Pour mieux visualiser l'impact de ces incohérences, Le diagramme ci-dessous illustre un scénario type de gestion d'un besoin d'achat dans lequel le système d'achat interroge plusieurs référentiels (investissement, ventes, pièces de rechange, économat…) pour identifier le code produit et sa source. La diversité des règles de codification engendre des doublons ou des divergences pouvant conduire à des incohérences dans l'intégration en stock. Cette hétérogénéité complique le suivi, la consolidation des informations et la fiabilité des données pour la prise de décision.

Définitions et abréviations

- **BC** : Bon de Commande
- **BL** : Bon de Livraison ou Bon de Réception
- **Source** : Système d'information ou référentiel d'origine de la donnée produit
- **Référentiel** : Base de données interne ou catalogue dans lequel sont stockées les informations des articles

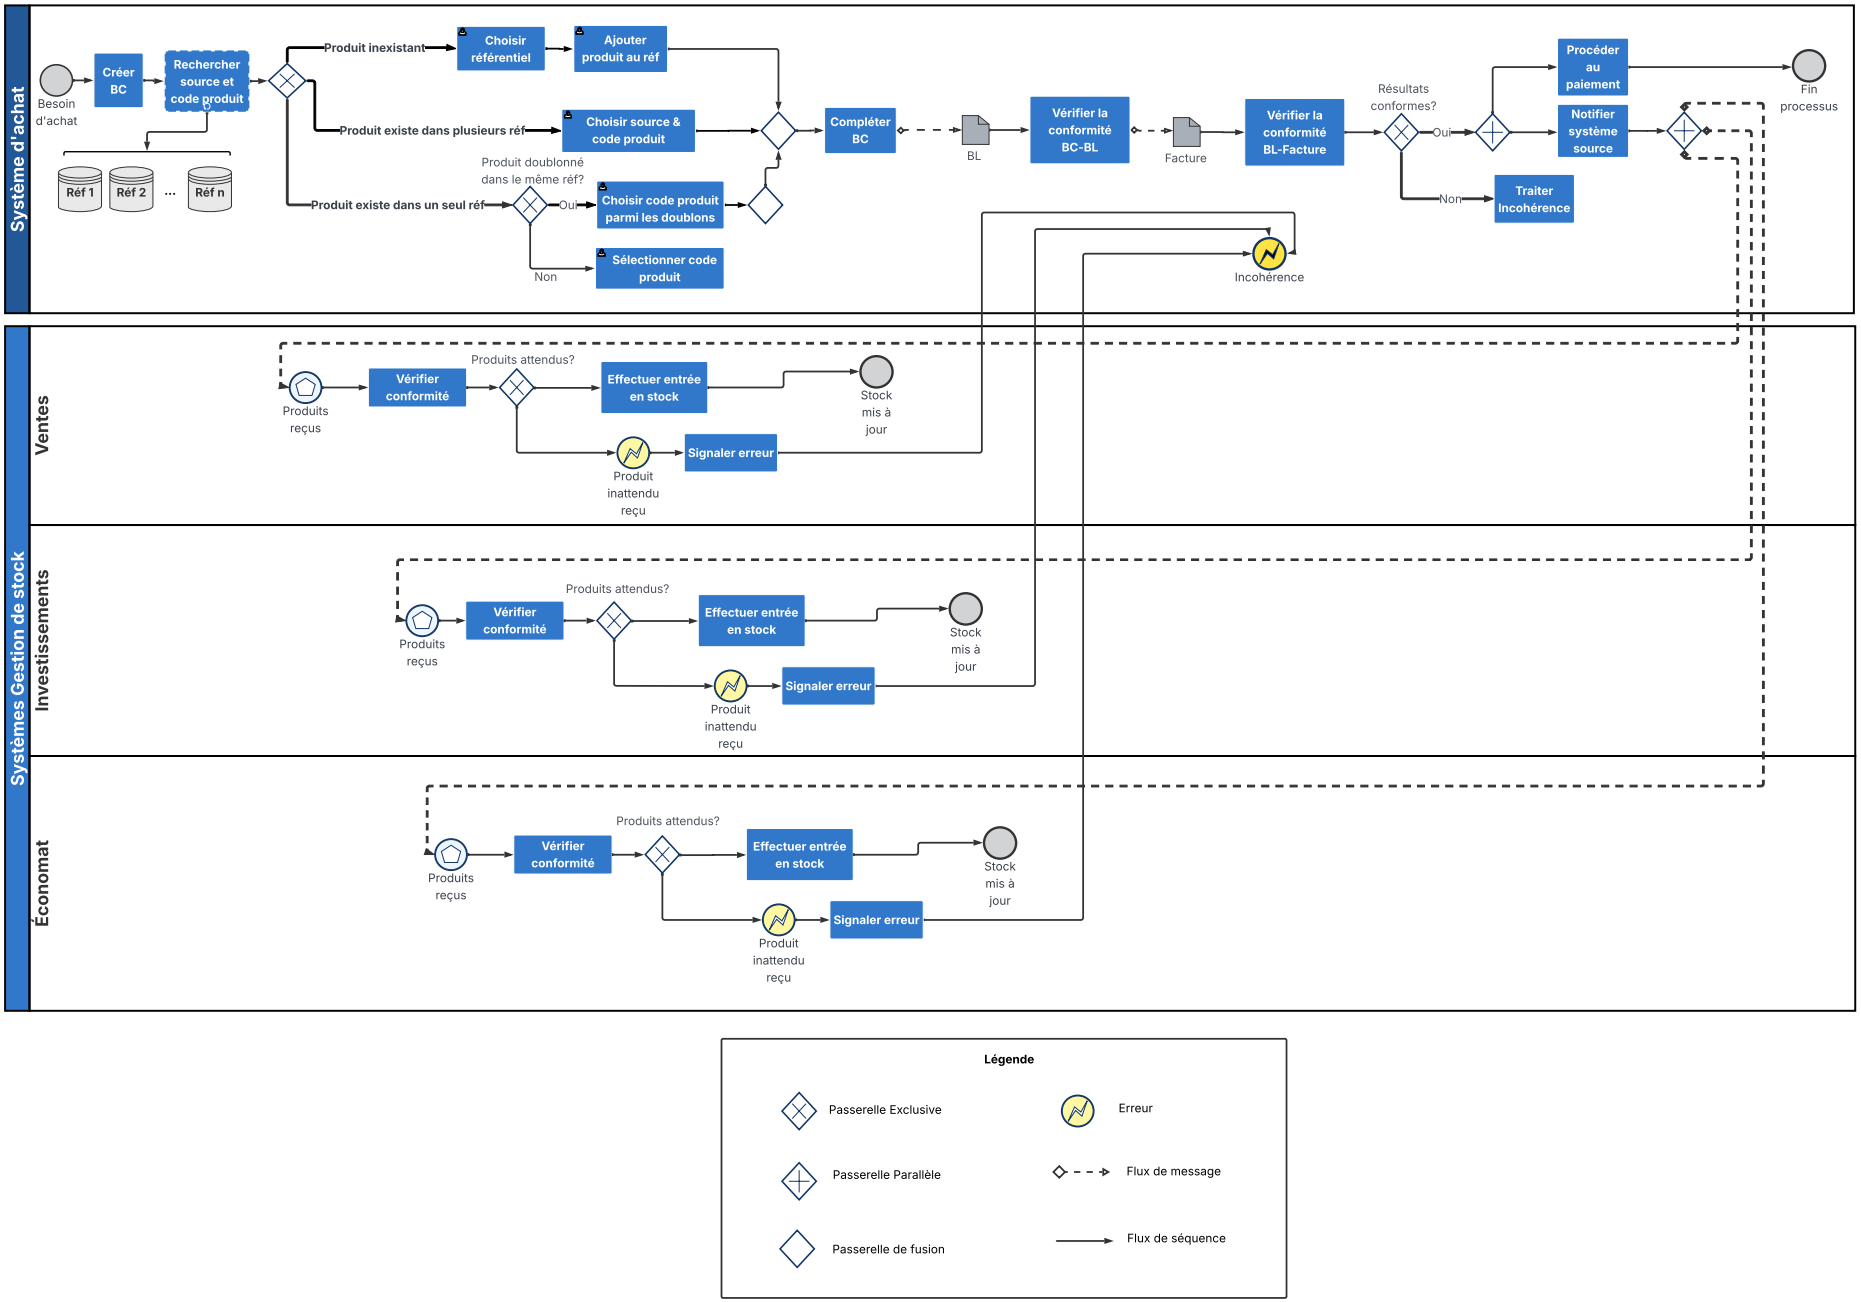

FIGURE 1.6 – Processus métier - gestion des besoins d'achat

Remarque : Le diagramme de la figure 1.6 met en évidence le point critique où l'incompatibilité entre référentiels se manifeste, sans proposer de solution.

1.4.2.2 Architecture des systèmes d'information et flux de données

Les systèmes d'information de NAFTAL s'articulent autour d'un référentiel central, qui regroupe et unifie l'ensemble des données de référence de l'entreprise. Dans la pratique, certains systèmes exploitent directement ce référentiel, tandis que d'autres disposent de référentiels locaux autonomes, répondant à des besoins spécifiques de manière indépendante.

Cette dualité introduit une hétérogénéité dans le traitement des données : les systèmes centralisés assurent une cohérence globale, tandis que les systèmes autonomes peuvent générer des incohérences lorsqu'ils interagissent avec le référentiel central ou entre eux. Ces divergences sont particulièrement sensibles lors du rapprochement d'informations critiques, comme les données relatives aux produits ou aux stocks.

La figure 1.7 illustre cette organisation et met en évidence les flux de données principaux, ainsi que les zones où l'absence de synchronisation fiable peut engendrer des incohérences.

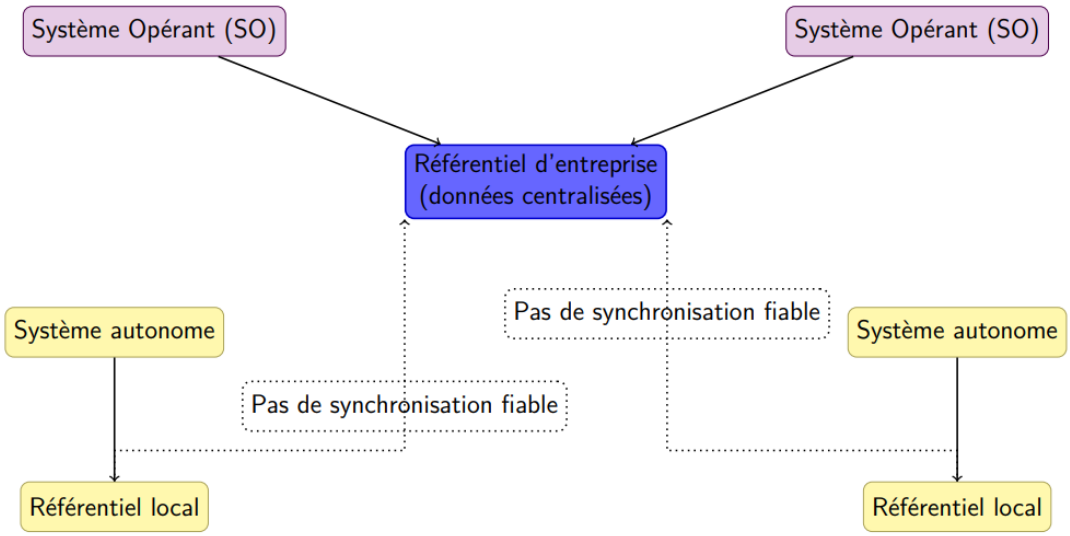

FIGURE 1.7 – Flux de données

1.4.3 Diagnostique

L'examen des systèmes d'information en place met en évidence des limites tant structurelles qu'opérationnelles, susceptibles d'impacter la fiabilité, la cohérence et l'exploitation des données. Le tableau ci-après en présente une synthèse, illustrée par des exemples représentatifs du fonctionnement quotidien des systèmes.

Contrainte	Exemple	Impact
Redondance et incohérence des données	Un même article est codifié ou nommé différemment d'un système à l'autre.	Création de doublons, difficulté d'identification fiable et complexification des recherches.
Règles de codification hétérogènes	Chaque référentiel applique ses propres règles de numérotation ou d'abréviation.	Incohérences lors de l'intégration et risque d'erreurs dans les traitements automatisés.
Hétérogénéité des structures de données	Des niveaux de classification (famille, sous-famille, agrégat, produit) qui varient d'un système à l'autre.	Perte de granularité, alignement difficile et analyses transversales limitées.
Absence de vision consolidée de l'information produit	Chaque service entretient son référentiel local de manière autonome.	Alourdissement des mises à jour, coûts de maintenance plus élevés et délais accrus.
Rigidité des systèmes existants	Applications métiers difficiles à faire évoluer pour intégrer de nouvelles règles.	Frein à l'adaptation et à l'harmonisation des processus.
Manque de traçabilité sur l'origine de la donnée	Difficulté à savoir quel système est **source de vérité** .	Affaiblit la qualité des contrôles et la responsabilisation.

Table 1.2 – Synthèse des contraintes identifiées

1.4.3.1 Objectifs

À la lumière de ces constats, les objectifs opérationnels du projet peuvent être précisés comme suit :

- **Unifier et fiabiliser l'information produit** par la normalisation des désignations hétérogènes.
- **Harmoniser la codification et regrouper les produits équivalents** afin d'éliminer les redondances.
- **Nettoyer et clarifier les désignations** en conservant l'intitulé principal et en supprimant les informations secondaires.
- **Mettre en place une classification hiérarchisée normalisée** assurant la cohérence et la compatibilité avec le référentiel central.

1.5 Conclusion

La description du cadre organisationnel et technologique de NAFTAL, suivie de l'analyse des systèmes d'information existants, met en évidence une architecture fragmentée et des référentiels hétérogènes. Ces constats soulignent la nécessité d'une normalisation et d'une harmonisation des données, qui orientera les travaux de ce stage.

Chapitre 2

État de l'art

2.1 Introduction

Ce chapitre présente les concepts et techniques clés sur lesquels s'appuie notre travail d'unification des désignations industrielles. Il explore notamment les modèles de langage et les approches alternatives, en mettant en lumière leurs potentialités et limites dans le traitement de données techniques complexes. L'objectif est de fournir un cadre de référence qui éclaire les choix méthodologiques à adopter pour la conception d'une solution efficace et adaptée à notre contexte industriel.

2.2 Modèles de langage : définitions et principes généraux

2.2.1 Modèles de langage.

Un modèle de langage (Language Model, LM) est un système probabiliste dont l'objectif est d'estimer la vraisemblance d'une séquence linguistique. Plus précisément, il cherche à prédire le mot ou le token suivant en fonction du contexte précédent. Ainsi, pour une séquence de tokens $w_1, w_2, \ldots, w_k$, la probabilité jointe est factorisée comme suit : [2]

$$P(w_1, w_2, \ldots, w_k) = \prod_{i=1}^{k} P(w_t \mid w_1, \ldots, w_{k-1}) \tag{2.1}$$

Historiquement, les modèles de langage ont connu plusieurs évolutions majeures. Les premières approches reposaient sur les *modèles n-grammes*, fondés sur une hypothèse de Markov : la probabilité d'un mot donné dépend uniquement des quelques mots qui le précèdent. Bien que simples et efficaces pour de courts contextes, ces méthodes se limitaient à une vision locale du langage et ne pouvaient pas capturer des dépendances sémantiques de longue portée.

Pour dépasser cette limite, les *réseaux de neurones récurrents* (RNN) ont été introduits. Ils traitent les séquences mot par mot en conservant une mémoire du passé, mais leur efficacité décroît rapidement lorsque la séquence s'allonge. Les variantes comme les *Long Short-Term Memory* (LSTM) ont apporté une meilleure gestion de l'information grâce à des mécanismes de mémoire plus sophistiqués, sans toutefois résoudre complètement le problème des dépendances lointaines.

L'introduction de l'architecture **Transformer** a marqué un tournant majeur dans le domaine du traitement automatique du langage. En abandonnant les mécanismes récurrents au profit du principe d'**attention**, elle offre la possibilité de traiter simultanément l'ensemble des tokens d'une séquence et de modéliser de manière précise les dépendances, y compris lorsqu'elles se situent à de grandes distances. Cette avancée a rendu possible l'entraînement de modèles de très grande échelle, capables de saisir des régularités complexes dans les données textuelles et de transférer ces connaissances à une large gamme de tâches.[1]

2.2.2 Large Language Models (LLMs).

Les LLMs représentent une sous-catégorie particulière de modèles de langage, définie par trois caractéristiques essentielles :

1. une échelle massive en nombre de paramètres (allant jusqu'à plusieurs dizaines de milliards),
2. un entraînement sur des corpus extrêmement volumineux et diversifiés (données scientifiques, techniques et textuelles générales),
3. une capacité de généralisation remarquable, leur permettant de résoudre de nouvelles tâches en exploitant simplement des instructions formulées dans le prompt, sans nécessiter un apprentissage supervisé additionnel.

Ces propriétés distinguent nettement les LLMs des modèles de langage traditionnels, en leur conférant une flexibilité et une puissance adaptées à des problématiques complexes.

2.2.3 L'architecture Transformer

Le Transformer repose sur une chaîne de traitement séquentielle et modulaire permettant de convertir une séquence d'entrée en une séquence de sortie. Le processus débute par une étape d'**embedding**, qui transforme les tokens d'entrée en vecteurs continus de dimension d_{model}, rendant les données exploitables par le modèle. À ces représentations est ajouté un **encodage positionnel**, destiné à injecter une information d'ordre dans la séquence, puisque l'architecture ne comporte ni récurrence ni convolution. Ces vecteurs enrichis sont ensuite transmis à une pile d'**encodeurs**, dont la sortie alimente à son tour une pile de **décodeurs**, responsables de la génération séquentielle des tokens de sortie. À la fin, on transforme les vecteurs du modèle en probabilités sur tout le vocabulaire, grâce à une projection linéaire suivie d'un softmax.[1]

2.2.3.1 Encodage positionnel

Le Transformer ne possédant pas de mécanisme récurrent ou convolutionnel, il ne dispose pas d'une notion implicite de l'ordre des tokens. Pour introduire cette information, un encodage positionnel sinusoïdal est ajouté à chaque vecteur d'entrée. :

$$PE_{(pos,2i)} = \sin\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right), \quad PE_{(pos,2i+1)} = \cos\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right) \tag{2.2}$$

où :

- $pos \in \{0, 1, 2, \dots\}$ désigne l'index de la position du token dans la séquence,
- d_{model} correspond à la dimension du vecteur d'embedding,
- $i \in \{0, 1, \dots, \frac{d_{\text{model}}}{2} - 1\}$ est un compteur qui indexe les dimensions de l'encodage,

2.2.3.2 Encodeur

L'encodeur est constitué d'une pile de N couches identiques. Chaque couche comprend :

1. un mécanisme d'**attention multi-tête**, qui met en relation chaque vecteur de la séquence avec l'ensemble des autres,
2. un réseau **feed-forward positionnel**, appliqué indépendamment à chaque position.

Chacune de ces sous-couches est entourée d'une connexion résiduelle et suivie d'une normalisation de couche, ce qui favorise une propagation stable du gradient et améliore la convergence lors de l'apprentissage. Ainsi, l'encodeur transforme la séquence initiale en une suite de représentations vectorielles enrichies en dépendances contextuelles.

2.2.3.3 Décodeur

Le décodeur adopte une structure analogue, mais comporte trois sous-couches :

1. un **mécanisme d'attention masquée** appliqué à la séquence cible, garantissant qu'un token ne dépend que des positions antérieures (modélisation autoregressive).
2. un **mécanisme d'attention croisée**, qui combine la sortie de l'encodeur avec les représentations issues de l'attention masquée.
3. un **réseau feed-forward positionnel**, de structure identique à celui de l'encodeur.

Cette architecture permet au modèle de générer pas à pas la séquence de sortie, tout en exploitant simultanément le contexte de l'entrée et celui des tokens déjà produits.

2.2.3.4 Mécanisme d'attention

Le mécanisme d'attention constitue le cœur du modèle Transformer. Il permet de pondérer chaque token en fonction de sa pertinence par rapport aux autres tokens de la séquence.

Pour des matrices de requêtes Q, de clés K et de valeurs V, l'attention est définie par :

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V, \tag{2.3}$$

où :

- d_k est la dimension des vecteurs clés,
- softmax une fonction permettant de transformer les scores en probabilités normalisées, de sorte que la somme des poids associés à chaque token soit égale à 1. Les tokens les plus pertinents reçoivent des poids plus élevés.

Pour capturer différentes relations contextuelles, le mécanisme multi-têtes est utilisé :

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \ldots, \text{head}_h) W^O \tag{2.4}$$

avec

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V), \tag{2.5}$$

où chaque élément a un rôle précis :

- W_i^Q, W_i^K, W_i^V : matrices de projection apprises pour chaque tête i, permettant de calculer les relations entre tokens dans un sous-espace spécifique.
- $\mathbf{head}_i$: sortie de la i^{ème} tête d'attention.
- **Concat** : opération de concaténation des sorties de toutes les têtes le long de la dimension des caractéristiques, combinant les informations de différentes perspectives.
- W^O : matrice de projection finale qui ramène la représentation concaténée à la dimension initiale.

Ainsi, le mécanisme d'attention multi-têtes permet au modèle de considérer simultanément plusieurs types de dépendances entre tokens, enrichissant considérablement la représentation contextuelle de la séquence.

2.2.3.5 Réseau feed-forward positionnel

Chaque couche contient également un réseau feed-forward positionnel, appliqué séparément à chaque vecteur :

$$\mathrm{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2 \tag{2.6}$$

où W_1, W_2 sont des matrices de projection apprises et b_1, b_2 des vecteurs de biais.

Cette opération consiste à projeter chaque vecteur vers un espace de dimension plus élevée, à appliquer une transformation non linéaire, puis à le ramener à sa dimension initiale, enrichissant ainsi la représentation de chaque token.

L'architecture du transformer est illustré par la figure suivante :

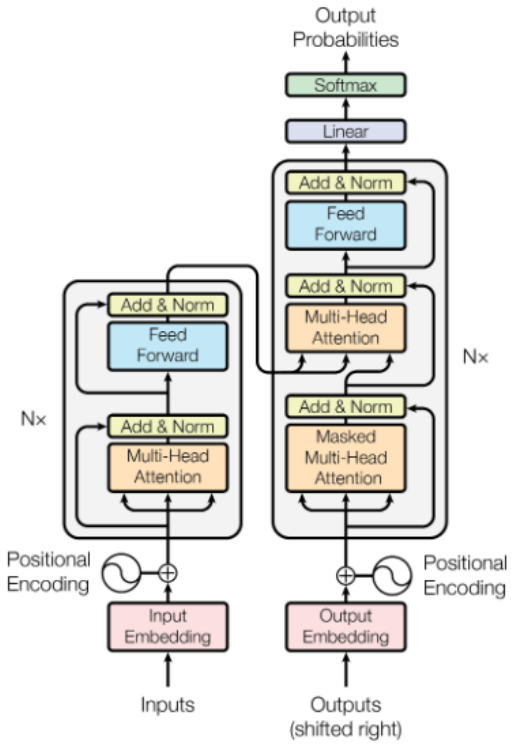

FIGURE 2.1 – Architecture générale du Transformer (extraite de [1]).

2.2.4 Limites opérationnelles des API de modèles de langage

L'utilisation des modèles de langage via des API soulève des considérations pratiques liées à leurs limites techniques. Parmi les plus importantes figurent le nombre maximal de tokens pouvant être traités par requête et la fréquence autorisée des appels à l'API.

Si l'on note :

- N le nombre total d'entrées à traiter,
- n le nombre moyen de tokens par entrée,

le nombre total de tokens à traiter s'exprime par :

$$T_{\text{total}} = N \times n \tag{2.7}$$

Lorsque chaque requête est limitée à $T_{\max}$ tokens, le nombre minimal de requêtes nécessaires est :

$$R = \left\lceil \frac{T_{\text{total}}}{T_{\max}} \right\rceil \tag{2.8}$$

Enfin, si l'API impose un nombre maximal de requêtes par unité de temps $R_{\max}$, le temps total estimé pour traiter toutes les entrées est :

$$\text{Temps}_{\text{total}} = \frac{R}{R_{\max}} \quad \text{unités de temps} \tag{2.9}$$

Ces formules offrent une estimation générale, applicable à toute utilisation d'API de modèles de langage, et permettent de comparer différents fournisseurs en fonction de leurs caractéristiques techniques (limites de tokens, fréquence des requêtes, coûts, etc.).

Le tableau ci-dessous présente un exemple de comparaison pour l'utilisation du modèle `meta-llama/llama-3.3-70b-instruct` via différentes API.

API / Fournisseur	**Limite de tokens par minute**	**Requêtes max**
OpenRouter [7]	65 536	20 requêtes/min
Cerebras [8]	60 000	30 requêtes/min
Groq [9]	6 000	1 000 requêtes/jour
Together AI [10]	-	-

Table 2.1 – Caractéristiques techniques des principales API de modèles de langage.

2.2.5 Approches existantes

Plusieurs approches traditionnelles ou basées sur des modèles spécialisés ont été proposées dans la littérature pour le nettoyage et l'unification des désignations techniques. Le tableau 2.2 synthétise certaines de ces approches, en indiquant leur nature et leurs principales limites dans le contexte du traitement de désignations industrielles (pièces de rechange et installations fixes).

Approche	Description	Nature	Limites
TF-IDF + Similarité Cosine	Représentation vectorielle basée sur la fréquence des termes et pondération inverse de la fréquence des documents, suivi d'un calcul de similarité pour grouper les désignations proches.	Bibliothèque / méthode statistique	Ne capture pas la sémantique complexe ; sensible aux synonymes et variations d'orthographe ; difficile à gérer les spécifications techniques ou l'attribution hiérarchique (famille, sous-famille, agrégat).
Sentence Transformers (BERT, SBERT)	Génère des embeddings pour phrases ou désignations complètes, facilitant la comparaison et le clustering de séquences entières.	Modèle pré-entraîné / bibliothèque Python	Performances dépendantes du corpus d'entraînement ; difficultés sur les termes ultra-techniques non présents dans le corpus ; le clustering peut produire des groupes incohérents pour des désignations complexes.
Modèles supervisés de classification	Modèles entraînés pour attribuer des catégories (famille, sous-famille, etc.) à partir d'un jeu de données étiqueté.	Modèle supervisé	Nécessite un jeu de données industriel volumineux et bien annoté ; difficile de gérer des désignations inédites ou extrêmement techniques ; faible flexibilité sur de nouvelles sources.

Table 2.2 – Principales approches existantes pour l'unification des désignations industrielles.

2.3 Conclusion

Ce chapitre a permis de situer les modèles de langage dans le paysage des techniques de traitement et d'unification des désignations, en comparant leur puissance et leurs contraintes avec celles d'approches plus traditionnelles. Il apparaît que, bien que performants pour capturer la sémantique et gérer des désignations variées, ces modèles doivent être utilisés en tenant compte de limites pratiques et du contexte industriel spécifique. Les éléments présentés ici servent de fondement pour la conception d'une approche adaptée, qui sera détaillée dans le chapitre suivant.

Chapitre 3

Conception

3.1 Introduction

Le présent chapitre est consacré à la conception du système proposé. Dans la continuité de l'analyse de l'état de l'art, il s'attache à traduire les enseignements théoriques et les contraintes identifiées en une architecture méthodologique claire et opérationnelle. Cette étape établit les spécifications, l'organisation des données ainsi que les principes de classification et de codification qui structurent la solution.

3.2 Expression des besoins et spécifications

3.2.1 Expression des besoins

Le besoin fondamental identifié concerne l'unification des désignations industrielles hétérogènes, provenant à la fois des bases internes de l'entreprise et de sources externes. Cette unification vise à garantir la cohérence sémantique des données, faciliter leur exploitation au sein du système d'information et permettre l'élaboration d'un référentiel fiable pour les processus métiers (achats, maintenance, gestion des stocks, etc.).

3.2.2 Spécifications fonctionnelles

Le système conçu doit répondre aux fonctionnalités suivantes :

ID	Spécification fonctionnelle	Priorité
1	Le système doit permettre la collecte des données issues de sources internes (datasets existants) et externes (web scraping).	M
2	Le système doit permettre le prétraitement des données : groupement, normalisation et standardisation des désignations.	M
3	Le système doit assurer une classification hiérarchique des articles (famille, sous-famille, agrégat, produit).	M

4	Le système doit permettre la génération d'une codification unifiée et unique pour chaque désignation.	M
5	Le système doit offrir un mécanisme de validation des résultats par les experts métier.	S
6	Le système pourrait permettre l'intégration progressive des données nettoyées dans d'autres systèmes de gestion.	C

Table 3.2 – Spécifications fonctionnelles du système avec priorités (MoSCoW)

3.2.3 Spécifications techniques

Sur le plan technique, le système doit :

- intégrer des techniques de traitement automatique du langage naturel (NLP) telles que la tokenisation et la lemmatisation pour le prétraitement des désignations textuelles.
- exploiter un modèle de langage de grande envergure (LLM) pour extraire automatiquement la désignation produit principale en supprimant les éléments non pertinents (dimensions, couleurs, marques, etc.).
- permettre de réaliser des regroupements sémantiques à partir des désignations nettoyées, en s'appuyant sur la compréhension contextuelle fournie par le LLM.

Ces choix techniques sont en adéquation avec les orientations définies dans le cahier des charges de l'entreprise, assurant ainsi la cohérence entre les exigences exprimées en amont et la conception méthodologique proposée.

3.3 Architecture adoptée

La solution repose sur une **architecture monolithique modulaire**. L'ensemble du traitement est regroupé au sein d'une seule application, mais organisée en modules distincts assurant chacun une fonction précise :

- **Prétraitement des données** : normalisation, nettoyage et préparation des désignations textuelles issues des différentes sources.
- **Classification** : organisation des désignations selon une structure hiérarchique cohérente.
- **Codification** : attribution de codes standardisés aux produits.
- **Mapping des produits** : mise en correspondance des nouvelles désignations avec les produits existants et préparation des résultats pour intégration.

Les sources de données comprennent à la fois les **bases de données internes de l'entreprise** et un **dataset externe construit**. Les résultats finaux sont intégrés dans la base de données interne et sont consultables via une **application web** servant d'interface de visualisation et d'interaction.
La figure 3.1 illustre cette architecture monolithique modulaire.

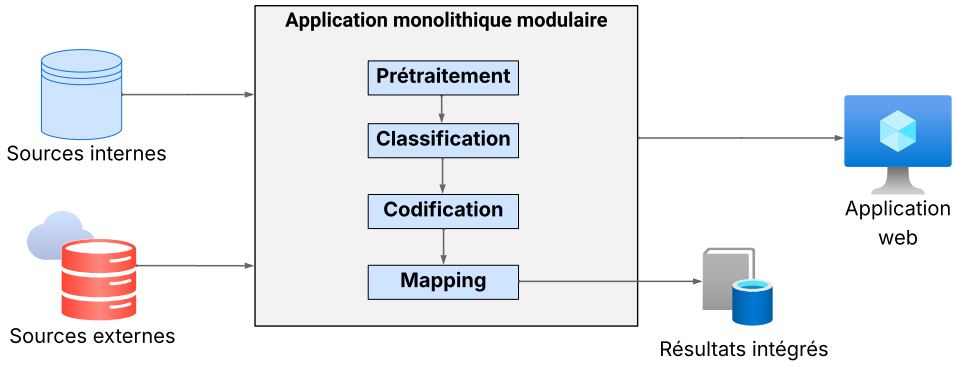

FIGURE 3.1 – Architecture monolithique modulaire de la solution.

3.4 Collecte des données

La phase de collecte constitue le point d'entrée du processus de conception. Elle vise à recenser, agréger et préparer les informations nécessaires à l'unification des désignations industrielles. Deux catégories de sources ont été exploitées : les données internes, issues directement du système d'information de l'entreprise, et les données externes, collectées sur des plateformes spécialisées.

3.4.1 Sources internes

Les données internes regroupent les datasets de pièces de rechange et d'installations fixes gérés par le système d'information actuel. Ces jeux de données représentent la base de référence pour le projet, car ils reflètent fidèlement la nomenclature et les spécifications techniques utilisées par l'entreprise.
Afin de fournir un aperçu global de ces datasets, des statistiques descriptives ont été établies :

Dataset	**Nombre d'enregistrements**	**Nombre de désignations uniques**	**Attributs principaux**
Pièces de rechange	62 732	33 050	ID_ARTI ; ID_ARTI_MERE ; REFE_ARTI ; CODE_STRU ; ID_MARQ ; ID_FAMI ; DESI_ARTI
Installations fixes	73 006	46 014	ID_ARTI ; ID_ARTI_MERE ; REFE_ARTI ; CODE_STRU ; ID_MARQ ; ID_FAMI ; DESI_ARTI

TABLE 3.3 – Statistiques générales sur les jeux de données internes.

3.4.2 Sources externes

En complément des données internes, des sources externes ont été intégrées pour enrichir la hiérarchie des désignations. Sur recommandation du **département Transformation**

Digitale, l'ensemble des sous-familles et agrégats du site web Oscaro[11] a été collecté via des techniques de web scraping. [1].
Les statistiques suivantes peuvent être présentées dans le tableau 3.4 :

Source externe	Sous-familles extraites	Agrégats extraits
Oscaro (site web)	20	164

TABLE 3.4 – Statistiques générales sur les données collectées en source externe.

3.5 Prétraitement des données

Afin d'assurer l'uniformité des désignations produits et de mettre en place une codification claire, un processus rigoureux de nettoyage et de préparation des données a été conduit. Celui-ci s'articule autour de trois sous-étapes principales : groupement des jeux de données et normalisation des désignations.

3.5.1 Sélection des variables pertinentes

Dans un premier temps, seules les colonnes indispensables à la constitution du référentiel ont été retenues :

- **ID_ARTI** : identifiant unique de chaque article, nécessaire pour établir ultérieurement une table de correspondance entre désignations initiales et codes attribués.
- **DESI_ARTI** : désignation textuelle de l'article, support des opérations d'harmonisation et de regroupement.

Les colonnes relatives aux marques, aux fournisseurs ou à d'autres attributs non pertinents pour la codification ont été écartées afin d'éviter l'introduction de bruit et de concentrer le traitement sur les variables clés.

3.5.2 Groupement des jeux de données

Les deux jeux de données — *pièces de rechange* et *installations fixes* — présentent des désignations parfois identiques. Pour éviter des traitements redondants et garantir l'unification des résultats, les deux ensembles ont été fusionnés en conservant pour chaque enregistrement son identifiant ainsi qu'une référence à la source d'origine.
Ce processus a permis de réduire considérablement le volume d'entrées à traiter par la suite : au lieu de traiter séparément la somme des deux jeux (135 738 enregistrements), le regroupement a ramené l'ensemble à **74 157 enregistrements uniques**, optimisant ainsi les étapes ultérieures de normalisation et de standardisation.

3.5.3 Normalisation des désignations

Afin de préparer les désignations à la codification, un processus unique de normalisation a été appliqué sur la colonne **DESI_ARTI**. Ce processus combine deux volets complémentaires :

1. Le web scraping désigne un ensemble de techniques informatiques permettant d'extraire automatiquement des données publiées sur des sites web en analysant la structure de leurs pages (HTML, scripts, etc.) afin de les convertir en un format exploitable pour un traitement ultérieur

- **Correction et harmonisation du format** : traitement des incohérences de saisie et des variations typographiques, suppression des espaces superflus et des caractères indésirables.
- **Épuration du contenu** : retrait des informations non essentielles (par exemple couleurs, références) et uniformisation des termes ou abréviations récurrentes.

Ces transformations visent à produire une base de désignations épurée, cohérente et prête pour le traitement sémantique.

3.6 Classification hiérarchique

Cette étape vise à attribuer à chaque désignation nettoyée une position précise au sein de la hiérarchie définie (famille, sous-famille, agrégat et nom de produit). Contrairement aux approches traditionnelles, fondées sur des heuristiques [2] reposant principalement sur la similitude lexicale, la méthode retenue s'appuie sur un modèle de langage de grande envergure capable d'exploiter la compréhension sémantique des termes techniques.
L'originalité de cette classification réside dans le fait qu'elle ne se limite pas à assigner des catégories préexistantes : elle combine, d'une part, la **génération automatique de familles et de produits** à partir des désignations analysées, et, d'autre part, l'**association de ces produits générés aux sous-familles et agrégats** préalablement collectés par web scraping. Cette double approche permet de construire une taxonomie cohérente et enrichie, en intégrant à la fois les connaissances internes (issues du nettoyage des données) et les informations externes collectées en amont.

3.6.1 Modèle retenu et justification

Le modèle choisi pour cette tâche est `meta/llama-3.3-70B-instruct-turbo`, accessible via l'API Together AI. Ce choix repose sur plusieurs critères techniques et stratégiques, étayés par des publications et des documentations techniques dont un résumé figure en Annexe A. :

- **Capacité du modèle** : ce modèle compte 70 milliards de paramètres, ce qui lui confère une expressivité élevée pour modéliser des relations complexes entre termes techniques.
- **Optimisations pour l'inférence** : la version "Turbo" intègre des optimisations visant à accélérer le processus de génération de texte, notamment via quantification et noyaux optimisés, ce qui peut réduire la latence lors du traitement de grands volumes.
- **Compatibilité avec l'architecture API** : la limite de contexte étendue du modèle permet d'intégrer des désignations plus longues, et son fonctionnement en mode "instruct" facilite la formulation de prompts ciblés pour l'assignation hiérarchique.
- **Robustesse face aux variations terminologiques** : contrairement à des modèles plus légers, ce modèle dispose d'un entraînement plus large, ce qui lui permet de mieux gérer les synonymes, les abréviations et les variations orthographiques techniques.

2. Une heuristique correspond à une méthode approximative ou intuitive permettant de simplifier la résolution de problèmes complexes lorsque des solutions exactes sont trop coûteuses ou impraticables.

3.6.2 Traitement par lots

Après le groupement des jeux de données, 74 157 désignations restaient à classer. Afin de respecter les limites de tokens imposées par l'API et de contrôler la charge de requêtes, les données ont été divisées en lots de taille fixe. Chaque lot est soumis au modèle avec le même prompt, garantissant une cohérence dans la classification.

3.6.3 Parallélisme via multithreading

Pour optimiser la durée de traitement, un mécanisme de multithreading a été mis en place au niveau client. Plusieurs lots sont envoyés simultanément dans des threads distincts, chaque thread transmettant ses requêtes au modèle. Cela permet de tirer parti de la latence réseau et du traitement simultané des requêtes pour accélérer le flux global, tout en conservant l'uniformité des résultats.

3.6.4 Processus de validation

Les classifications produites par le modèle sont soumises à un contrôle par le département *Architecture et Urbanisation* en collaboration avec l'équipe du *Département Transformation Digitale*. Cette validation sert à :

- Vérifier la cohérence structurelle des attributions (famille, sous-famille, agrégat, produit).
- Corriger les cas ambigus ou les erreurs identifiées.
- Garantir la conformité aux standards métier avant codification finale.

3.7 Codification

À l'issue de la phase de classification et de validation par l'équipe métier, les désignations harmonisées sont traduites en un code alphanumérique unique. Ce code constitue l'identifiant de référence du produit dans le système cible et a pour objectif d'assurer une organisation hiérarchique tout en facilitant la gestion et la recherche.
Le principe retenu repose sur une concaténation progressive des niveaux hiérarchiques :

- **Famille** : représentée par 2 caractères, reflétant le niveau le plus large de classification.
- **Sous-famille** : représentée par 1 caractère, attribué de manière unique au sein de chaque famille. En cas de collision, un caractère alternatif (un chiffre) est utilisé pour garantir l'unicité.
- **Agrégat** : représenté par 1 caractère, attribué de manière unique au sein de chaque sous-famille, avec un mécanisme similaire de gestion des collisions
- **Séquentiel produit** : un numéro séquentiel à 5 chiffres, permettant de distinguer les produits au sein d'une même combinaison famille/sous-famille/agrégat.

Ainsi, la codification fournit une clé structurée et évolutive, garantissant à la fois la traçabilité et l'intégration harmonieuse des produits dans le référentiel unifié.

3.8 Alignement des codes produits

À l'issue de la codification, deux référentiels distincts et structurés sont obtenus : celui des *pièces de rechange* et celui des *installations fixes*. Pour relier ces ensembles et assurer la traçabilité entre le référentiel central et les référentiels sources, une **table de correspondance** est mise en place.
Cette table associative rattache chaque produit du référentiel central à son ou ses équivalents issus des référentiels sources. Elle enregistre, pour chaque correspondance, le **code produit central**, le **code produit source** ainsi que la **source d'origine**. Elle constitue ainsi l'élément pivot permettant d'identifier les chevauchements entre jeux de données et de garantir une vision consolidée et cohérente du catalogue produit.

Remarque *: seuls les attributs pertinents à notre cas d'étude ont été représentés dans le modèle entité association et le modèle relationnel corrspondant.*

3.8.1 Modèle entité-association

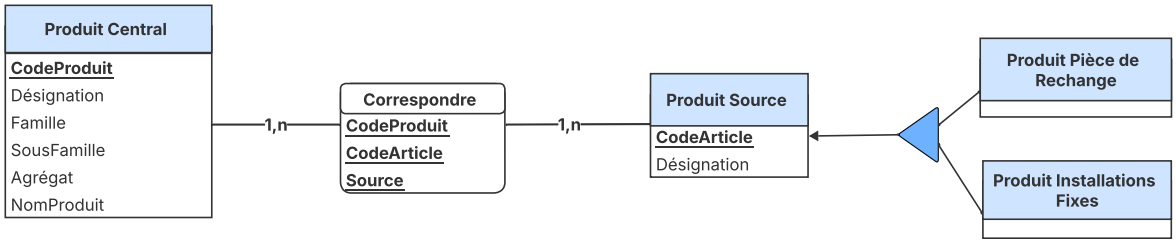

FIGURE 3.2 – Modèle entité–association de l'alignement des produits

3.8.2 Modèle relationnel

À partir du modèle entité–association, on obtient le modèle relationnel suivant :

- ProduitCentral(CodeProduit, Désignation, Famille, SousFamille, Agrégat, NomProduit)
- ProduitSource(CodeArticle, Désignation, TypeSource)
  avec TypeSource indiquant "Pièce de rechange" ou "Installation fixe"
- Correspondre(CodeProduit, CodeArticle, Source)
  CodeProduit référence ProduitCentral.CodeProduit
  CodeArticle référence ProduitSource.CodeArticle

Ce modèle relationnel traduit la même logique que le schéma entité–association et sert de base à la mise en œuvre dans une base de données.

3.9 Conclusion

Ce chapitre a présenté la conception méthodologique du système, depuis l'expression des besoins jusqu'à la définition des étapes clés : collecte, prétraitement, classification hiérarchique, codification et alignement des produits. L'ensemble de ces choix établit une architecture cohérente et structurée, garantissant l'unification et la traçabilité des désignations industrielles.
Cette conception constitue désormais la base sur laquelle s'appuiera la phase de réalisation.

Chapitre 4

Implémentation

4.1 Introduction

Ce chapitre est consacré à la mise en œuvre pratique de la solution proposée. Il décrit l'environnement de développement, les choix technologiques retenus ainsi que les principaux aspects liés à l'implémentation. Une attention particulière est portée à l'interface applicative, qui constitue le point d'accès central aux fonctionnalités développées et permet de concrétiser les concepts définis lors des étapes de conception. Ainsi, ce chapitre établit le lien entre la modélisation théorique et la réalisation effective du système.

4.2 Environnement technique adopté

La mise en œuvre de la solution a été réalisée sur la plateforme **Google Colaboratory (Colab)**, qui fournit un environnement cloud préconfiguré adapté aux besoins en calcul scientifique et en apprentissage automatique. Colab offre une infrastructure souple et prête à l'emploi, intégrant de nombreuses bibliothèques spécialisées et facilitant l'ajout de dépendances externes, ce qui en fait un cadre efficace pour l'expérimentation et le prototypage.

4.2.1 Langage de programmation

Le développement a été effectué en **Python 3.12.11**, un langage largement adopté dans le domaine scientifique et en intelligence artificielle. Sa syntaxe claire et expressive, associée à un écosystème particulièrement riche en bibliothèques pour le traitement de données, le calcul numérique et le *Natural Language Processing* (NLP), en fait un outil privilégié pour la manipulation de données textuelles et l'intégration de modèles avancés.

4.2.2 Bibliothèques Python

Le développement de la solution s'est appuyé sur un ensemble de bibliothèques Python spécialisées :

- **Pandas** : manipulation et analyse de données tabulaires, assurant une gestion efficace de grands volumes de données textuelles.
- **Scikit-learn (cosine_similarity)** : génération de représentations vectorielles des désignations textuelles et évaluation de leur proximité sémantique au moyen de la mesure de similarité cosinus (Annexe B).

- **Rapidfuzz** : comparaison approximative de chaînes, robuste aux variations orthographiques et fautes typographiques, complémentaire à Scikit-learn pour les cas non couverts par les représentations vectorielles.
- **Plotly** : génération de visualisations interactives des résultats et personnalisation des graphiques pour l'interprétation des données.
- **Streamlit** : création d'interfaces interactives pour le déploiement des tableaux de bord et l'exploration des résultats en temps réel.
- **Unicodedata** : gestion et normalisation des caractères Unicode, assurant une homogénéité des désignations textuelles issues de sources hétérogènes.
- **Bibliothèque standard `concurrent.futures` (ThreadPoolExecutor)** : parallélisation de l'envoi des requêtes afin de réduire les temps de traitement (Annexe C).
- **Bibliothèque standard `threading` (Lock)** : synchronisation des accès concurrents pour sécuriser les écritures dans les fichiers de sortie (Annexe D).
- **Tqdm** : suivi interactif et visualisation en temps réel de la progression des traitements.

4.2.3 Services et API externes

Pour le traitement sémantique des désignations textuelles, l'accès aux modèles de langage de grande envergure a été réalisé via la **Together API**. Cette API fournit une interface d'inférence pour le modèle `meta/llama-3.3-70B-instruct-turbo`, un modèle de type LLM (*Large Language Model*) capable de produire des embeddings textuels riches et d'évaluer la similarité sémantique entre textes.

Avantages

- Le modèle est hébergé et exécuté sur le cloud, évitant la nécessité de serveurs puissants ou de GPU locaux.
- L'API supporte l'envoi de lots de textes pour réduire le nombre d'appels réseau et optimiser le débit.

Paramètres d'exécution et optimisation

Pour maximiser l'efficacité du traitement, plusieurs paramètres ont été configurés :

- **Taille du batch** : les textes sont envoyés à l'API par groupes de N éléments ($N = 50$), ce qui permet de limiter le nombre d'appels réseau tout en respectant les contraintes du service.
- **Parallélisation via threads** : l'envoi des batchs est exécuté en parallèle à l'aide de `ThreadPoolExecutor`, avec T threads simultanés ($T = 4$) pour réduire le temps total de traitement.
- **Gestion des verrous et synchronisation** : pour éviter toute collision lors de l'écriture des résultats dans les fichiers de sortie, un verrou (`Lock`) est utilisé, garantissant la cohérence des données même en environnement multi-thread.
- **Gestion des erreurs et limites de l'API** : les requêtes non traitées, en raison d'erreurs réseau ou de dépassements de quotas, sont automatiquement réessayées

grâce à un mécanisme de retraitement, garantissant ainsi la robustesse et la fiabilité de l'implémentation.

4.3 Interface Utilisateur

L'application web développée, intitulée ***REFINOR***, constitue l'interface centrale de la solution proposée. Sa dénomination résulte de la contraction des termes suivants :

- ***REFI*** : Référentiel,
- ***NOR*** : Normalisation.

Cette appellation traduit la vocation première de l'outil, qui est de fournir une plateforme interactive dédiée à la normalisation, à la classification et à la codification des désignations produits. Développée au moyen du framework **Streamlit**, l'application assure une expérience utilisateur fluide et ergonomique, en intégrant des visualisations dynamiques et une navigation modulaire entre les différentes pages proposées.
La figure 4.1 illustre le logo de *REFINOR*, qui représente l'identité visuelle de l'application.

FIGURE 4.1 – Logo de l'application web

4.3.1 Structure générale de l'application

REFINOR repose sur une organisation en trois pages principales, accessibles via une barre latérale de navigation :

- **Accueil** : cette page constitue la porte d'entrée de l'application. Elle présente des statistiques globales relatives aux pièces de rechange ainsi qu'aux équipements et installations fixes. Elle permet ainsi une première exploration synthétique des données et fournit une vue d'ensemble des volumes et répartitions.
- **Pièces de rechange** : cette page est dédiée à l'analyse plus détaillée des produits de type pièces de rechange. L'utilisateur peut y visualiser et explorer les désignations à la fois avant et après les étapes de classification hiérarchique et d'harmonisation. Des graphiques interactifs y facilitent l'interprétation de la distribution et des tendances associées.
- **Installations fixes** : cette page, construite selon la même logique que celle des pièces de rechange, est consacrée aux équipements et installations fixes. Elle offre les mêmes fonctionnalités d'exploration et de comparaison, adaptées à ce second type de produits.

Ainsi, chaque page permet une visualisation et une exploration adaptées au niveau d'analyse recherché : de la vue globale sur la page d'accueil à l'examen plus fin sur les pages spécialisées.
Les interfaces correspondantes sont présentées ci-dessous. Il convient de préciser que, l'interface des installations fixes reposant sur une logique identique à celle des pièces de rechange, seule cette dernière a été illustrée.

4.3.2 Page d'accueil

(a)

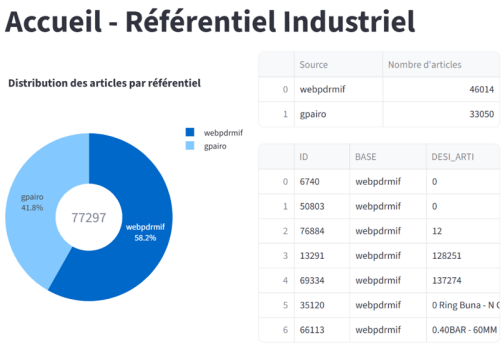

(b)

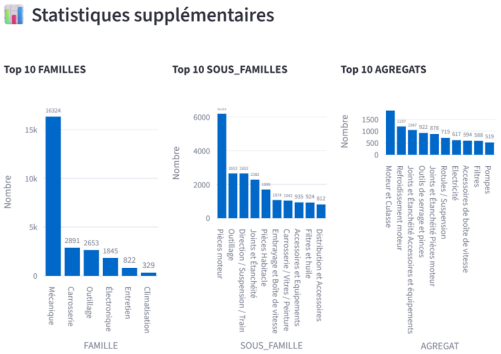

(c)

(d)

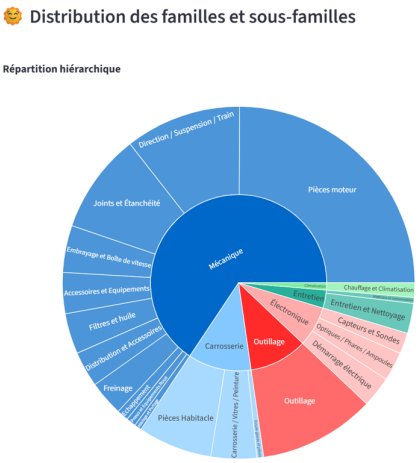

(e)

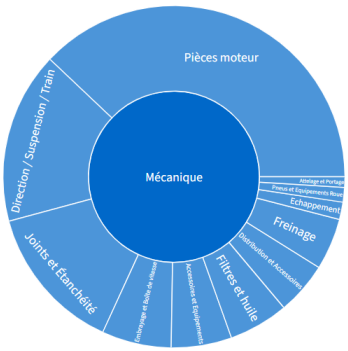

(e)

FIGURE 4.2 – Interface de la page d'accueil.

4.3.3 Page des pièces de rechange

FIGURE 4.3 – Interface de la page des pièces de rechange.

4.4 Conclusion

L'implémentation a permis de transformer l'approche conceptuelle en une solution concrète et fonctionnelle. Cette étape constitue un préalable essentiel à l'analyse critique de la performance et de la robustesse du système, analyse qui fera l'objet du chapitre suivant consacré à l'évaluation.

Chapitre 5

Évaluation

5.1 Introduction

Ce chapitre présente l'évaluation du système développé, en mobilisant des critères fonctionnels, techniques et ergonomiques. L'objectif est de vérifier non seulement la conformité aux spécifications initiales, mais également la performance opérationnelle et la qualité de l'expérience utilisateur. Cette démarche permet de valider la pertinence des choix effectués, d'identifier les limites éventuelles et de dégager des perspectives d'amélioration pour un déploiement futur.

5.2 Évaluation fonctionnelle

5.2.1 Évaluation fonctionnelle

L'évaluation fonctionnelle consiste à vérifier dans quelle mesure le système implémente les spécifications définies lors de la phase de conception. Cette validation se base sur des tests pratiques réalisés sur des jeux de données hétérogènes et sur une analyse qualitative des résultats obtenus.

ID	Spécification fonctionnelle	Évaluation
1	Collecte des données issues de sources internes et externes	Fonctionnalité correctement assurée, avec une intégration fiable des datasets et une compatibilité avec les modules en aval.
2	Prétraitement des données : groupement, normalisation et standardisation	Fonctionnalité opérationnelle, améliore l'homogénéité et la cohérence des désignations.
3	Classification hiérarchique des articles (famille, sous-famille, agrégat, produit)	Réalisée avec un haut degré de précision, cohérence hiérarchique maintenue même sur de larges volumes de données.
4	Génération d'une codification unifiée et unique pour chaque désignation	Fonctionnalité validée, assure une traçabilité et une consolidation efficaces des données hétérogènes.

5	Validation des résultats par les experts métier	Partiellement réalisée, un mécanisme d'interface de correction manuelle existe et s'avère pertinent pour les cas ambigus.
6	Intégration progressive des données nettoyées dans d'autres systèmes de gestion	Non implémentée dans le cadre de ce projet, cette tâche relève de l'équipe métier après la validation.

TABLE 5.2 – Évaluation fonctionnelle des spécifications du système

Dans l'ensemble, les fonctionnalités essentielles du système sont pleinement opérationnelles, garantissant la viabilité technique et la fiabilité du traitement des données. Les mécanismes complémentaires, tels que la validation experte et l'intégration avec des systèmes tiers, sont amorcés mais nécessitent des développements supplémentaires pour atteindre leur pleine maturité.

5.3 Évalution technique des performances

L'évaluation des performances du modèle `meta/llama-3.3-70B-instruct-turbo` appliqué au nettoyage et à la classification repose sur plusieurs dimensions techniques. Dans cette section, nous analysons principalement le temps d'exécution, la scalabilité, ainsi que la robustesse et la fiabilité du traitement.

5.3.1 Temps d'exécution

Le temps d'exécution constitue un indicateur essentiel de la performance du modèle. Grâce à l'optimisation de la version *Turbo* et à la prise en charge du parallélisme via *multithreading*, les résultats montrent des temps de traitement globalement rapides et compétitifs par rapport à d'autres modèles de taille et de capacité similaires.
Cependant, il convient de noter que l'évolution du temps n'est pas strictement linéaire. Plusieurs facteurs introduisent des variations :

- **Variabilité des prompts** : bien que normalisés, les prompts présentent des complexités linguistiques différentes influençant la vitesse d'inférence.
- **Boucles de relance** : certains lots incluent des entrées ambiguës ou inconnues, nécessitant une relance du traitement et générant ainsi une surcharge ponctuelle.
- **Infrastructures et contraintes réseau** : la disponibilité des ressources matérielles et les files d'attente sur l'API Together peuvent introduire des délais supplémentaires.

Ces éléments impliquent que le temps d'exécution doit être perçu comme une série présentant une **tendance globale stable et rapide**, mais ponctuée de **fluctuations locales**. Cette performance, qui combine rapidité et stabilité, constitue un atout majeur pour le déploiement opérationnel du modèle.

5.3.2 Scalabilité

La scalabilité du modèle se mesure à travers deux dimensions principales : **le temps d'exécution** et **la qualité des résultats**. Concernant le temps d'exécution, les réponses

restent stables à petite échelle et, grâce au parallélisme de l'architecture *Turbo*, le modèle parvient à absorber une charge croissante avec une dégradation limitée des performances, bien que dépendante de l'infrastructure d'hébergement. Du point de vue de la qualité, l'augmentation du volume de données n'affecte pas significativement la cohérence ni la précision des résultats, qui demeurent globalement stables.
Ainsi, la scalabilité renvoie non seulement à la rapidité de traitement mais aussi à la capacité du modèle à maintenir une qualité constante, condition essentielle pour un déploiement à grande échelle.

5.3.3 Robustesse et fiabilité

Outre la vitesse et la scalabilité, il est nécessaire de prendre en considération :

- **Gestion des erreurs et exceptions** : les mécanismes de retraitement assurent la continuité du traitement même en présence de données inconnues.
- **Stabilité temporelle** : bien que des variations existent, celles-ci ne compromettent pas la capacité globale du modèle à produire des résultats fiables.
- **Tolérance aux aléas d'exécution** : les fluctuations sont absorbées par une architecture de traitement robuste, garantissant une continuité opérationnelle.

Cette robustesse, renforce la fiabilité du système dans un contexte d'utilisation à grande échelle.

5.3.4 Considérations techniques globales

En définitive, l'évolution technique observée peut être résumée par trois constats principaux :

1. Un temps d'exécution rapide, permis par l'architecture *Turbo* et le parallélisme, malgré quelques variations liées à l'infrastructure.
2. Une scalabilité satisfaisante, conditionnée par la disponibilité des ressources et la gestion des appels parallèles.
3. Une bonne robustesse face aux erreurs, garantissant la fiabilité du traitement à grande échelle.

Ainsi, l'utilisation de `meta/llama-3.3-70B-instruct-turbo` pour le traitement de désignations hétérogènes s'avère techniquement viable, rapide et fiable, sous réserve d'une gestion appropriée des ressources et des délais.

5.4 Évaluation ergonomique

L'évaluation ergonomique de l'application a été effectuée à l'aide de l'outil *Lighthouse*, intégré à *Google PageSpeed Insights*. Cet outil, largement reconnu pour l'audit des applications web, fournit une analyse normalisée des performances, de l'accessibilité, de la conformité aux bonnes pratiques ainsi que de l'optimisation pour les moteurs de recherche (SEO).

5.4.1 Résultats obtenus

Les résultats de l'audit sont globalement très satisfaisants et témoignent de la qualité technique et ergonomique de l'application développée.[16] Les scores principaux sont synthétisés dans les figures ci-dessous.

(a) Audit PageSpeed – Version Mobile (b) Audit PageSpeed – Version Desktop

FIGURE 5.1 – Résultats des audits PageSpeed Insights pour les deux versions (Mobile et Desktop).

5.4.2 Analyse des résultats

- **Performance** : Les scores proches de 100, tant sur mobile que sur bureau, démontrent une excellente optimisation en termes de rapidité de chargement et de fluidité d'exécution. Cela garantit une expérience utilisateur réactive.
- **Accessibilité** : Bien que correcte (77), cette dimension peut être améliorée, notamment en renforçant l'usage d'attributs ARIA (Accessible Rich Internet Applications) et en validant certains éléments HTML pour garantir une meilleure inclusion des utilisateurs ayant des besoins spécifiques.
- **Bonnes pratiques** : Les scores supérieurs à 80 attestent d'une conformité satisfaisante aux standards actuels du développement web, tout en laissant apparaître quelques points perfectibles (sécurisation et validation d'attributs).
- **SEO (Search Engine Optimization)** : Le référencement naturel est bien pris en compte (92), assurant une visibilité correcte pour une application potentiellement déployée en production.

5.5 Analyse critique et perspectives

Apports principaux

Le projet a permis la mise en place d'un référentiel centralisé et structuré, garantissant une homogénéisation durable des désignations. La création d'une table de correspondance assure le lien avec les anciens référentiels, constituant une base solide pour l'intégration future dans les systèmes métiers.

Limites identifiées

L'intégration complète reste conditionnée par la validation des instances métier. Ce point, bien que légitime dans un cadre organisationnel réel, constitue actuellement le principal frein au déploiement en production.

Perspectives d'évolution

Une orientation prometteuse réside dans l'exploration de solutions hybrides, combinant l'IA et les règles métiers spécifiques afin d'améliorer la précision, notamment dans les cas ambigus. La mise en production du référentiel central pourra également servir de socle pour de futures évolutions stratégiques en matière de gouvernance des données.

5.6 Conclusion

L'évaluation réalisée confirme la viabilité et la maturité du système. Sur le plan fonctionnel, les spécifications majeures ont été implémentées avec succès, assurant une harmonisation et une traçabilité robustes des désignations. L'analyse technique a mis en évidence des performances satisfaisantes en termes de rapidité, de scalabilité et de fiabilité, tandis que l'audit ergonomique atteste de la qualité et de l'optimisation de l'application.
Si l'intégration complète aux systèmes métiers demeure conditionnée par une validation organisationnelle, l'existence d'un référentiel central structuré constitue déjà une avancée significative. Enfin, l'ouverture vers des solutions hybrides alliant intelligence artificielle et règles métiers laisse entrevoir un potentiel d'évolution stratégique pour la gouvernance des données.
Ainsi, le projet aboutit à un socle technique et organisationnel solide, directement exploitable et évolutif, répondant aux enjeux actuels de qualité et de cohérence des données.

Conclusion générale

Ce projet s'inscrit dans une dynamique de modernisation du système d'information de NAFTAL, dans un contexte où la maîtrise et la valorisation des données deviennent des leviers essentiels de performance. La multiplicité des référentiels produits et la diversité des formats de saisie rendaient difficile une exploitation cohérente et fiable de l'information. L'objectif principal a donc été d'instaurer une vision unifiée et cohérente de l'information, condition essentielle pour garantir la fiabilité, la traçabilité et l'efficacité des processus métiers.

Les travaux réalisés ont permis d'établir un référentiel central unifié, conçu pour harmoniser les désignations produits et faciliter leur intégration dans les différents systèmes existants. L'approche adoptée, fondée sur des méthodes d'analyse linguistique et d'intelligence artificielle générative, a montré qu'il est possible d'automatiser une part importante du processus tout en préservant la cohérence métier.

Au-delà de la réussite technique, ce projet représente une étape significative vers une meilleure exploitation des données au service des besoins opérationnels et décisionnels de NAFTAL. Il jette les bases d'un environnement plus intégré, où l'information circule de manière fluide entre les applications, réduisant ainsi les redondances et les risques d'erreur.

Pour la suite, plusieurs pistes d'amélioration peuvent être envisagées, notamment l'intégration complète du référentiel au sein des systèmes métiers et l'exploration de solutions hybrides combinant intelligence artificielle et règles spécifiques à chaque domaine. Ces évolutions permettraient d'accroître la précision et la fiabilité du modèle, tout en consolidant la transformation numérique engagée par l'entreprise.

Annexe A
Caractéristiques techniques du modèle `meta/llama-3.3-70B-instruct-turbo`

Cette annexe synthétise les caractéristiques techniques et les performances du modèle `meta/llama-3.3-70B-instruct-turbo` utilisé dans notre projet. Les informations sont issues des documentations officielles NVIDIA [12] et Together AI [13].

Environnement matériel

Le service d'inférence repose sur des serveurs équipés de deux GPU NVIDIA H100-80 GB SXM, assurant un haut débit et une faible latence lors du traitement des requêtes [13].

Caractéristique	**Valeur**
Nombre de paramètres	70 milliards
Architecture	Transformer « Instruct » optimisée pour prompts
Hardware d'inférence	2 × NVIDIA H100-80 GB SXM
Optimisation	Inférence haute performance à faible latence

TABLE 3 – Caractéristiques principales du modèle Llama 3.3 70B Instruct.

Performances sur benchmarks publics

Les performances du modèle Llama 3.3 70B Instruct présentées ci-dessous sont issues des évaluations effectuées et publiées par la plateforme Vals.ai [14], qui agrège les résultats sur divers jeux de tests académiques et propriétaires. .

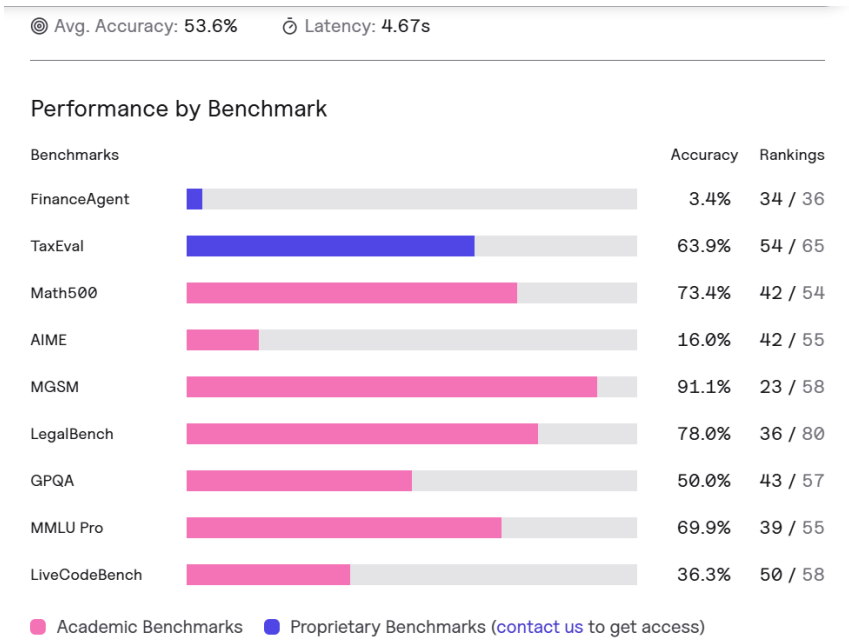

FIGURE 2 – Performances du modèle Llama 3.3 70B Instruct sur différents benchmarks (source : Vals.ai).

Annexe B
Similarité cosinus

Soit un ensemble de textes :

$$T = \{T_1, T_2, \ldots, T_n\}.$$

Chaque texte T_i est transformé en vecteur TF-IDF :

$$V_i = \text{TF-IDF}(T_i), \quad i = 1, \ldots, n.$$

La norme Euclidienne ($L2$) de chaque vecteur est :

$$||V_i|| = \sqrt{\sum_k V_{ik}^2}, \quad i = 1, \ldots, n.$$

La similarité cosinus entre deux vecteurs V_i et V_j est donnée par :

$$s_{ij} = \frac{V_i \cdot V_j}{||V_i||\,||V_j||}, \quad 1 \leq i, j \leq n.$$

On définit la matrice de similarité $S \in [0,1]^{n \times n}$ par :

$$S = \begin{bmatrix} s_{11} & s_{12} & \ldots & s_{1n} \\ s_{21} & s_{22} & \ldots & s_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ s_{n1} & s_{n2} & \ldots & s_{nn} \end{bmatrix}, \quad s_{ij} = s_{ji}.$$

Annexe C
Algorithme de parallélisme via ThreadPoolExecutor

Algorithm 1: Traitement parallèle des lots via un pool de threads

Input: Liste de lots à traiter $L = \{lot_1, lot_2, ..., lot_M\}$, nombre de threads N
Output: Résultats combinés de tous les lots
Initialisation : Créer un pool de N threads et une file de tâches vide Q;
for *chaque lot* $lot_i \in L$ **do**
  Placer lot_i dans la file de tâches Q;
while *la file de tâches Q n'est pas vide ou des threads sont actifs* **do**
  for *chaque thread t_j libre dans le pool* **do**
    Récupérer une tâche lot_k depuis Q;
    Exécuter lot_k dans le thread t_j de manière concurrente;
Synchronisation : Attendre que tous les threads aient terminé leurs tâches;
Combinaison : Récupérer les résultats de chaque thread et les fusionner pour obtenir le résultat final;
return *Résultats combinés*

Annexe D
Algorithme de synchronisation des écritures avec `Lock`

Algorithm 2: Synchronisation des écritures concurrentes dans les fichiers de sortie

Input: Liste de lignes à écrire $L = \{l_1, l_2, ..., l_n\}$, fichier de sortie f
Output: Fichier f contenant toutes les lignes écrites sans conflit
Initialisation : Créer un verrou *Lock*;
for *chaque thread* t_i *produisant des lignes* L_i **do**
  Acquérir le verrou *Lock*;
  Ouvrir le fichier f en mode ajout;
  Écrire les lignes L_i dans f;
  Fermer le fichier;
  Relâcher le verrou *Lock*;
Garantie : Aucune écriture simultanée n'a lieu, les données sont enregistrées de manière cohérente et sans corruption;

Références

Articles scientifiques

[1] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, Illia Polosukhin, *Attention is All You Need*, arXiv :1706.03762, 2017. Disponible en ligne : https://arxiv.org/pdf/1706.03762

[2] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah et al., *Language Models are Few-Shot Learners*, arXiv :2005.14165, 2020. Disponible en ligne : https://arxiv.org/pdf/2005.14165

Références web

[3] Site officiel de NAFTAL : https://www.naftal.dz/fr/...

[4] NAFTAL Khadamat : application mobile permettant aux clients d'accéder aux services NAFTAL. Disponible sur Google Play : https://play.google.com/...

[5] Plateforme MyNAFTAL : espace client en ligne pour la gestion des services. https://mynaftal.naftal.dz/

[6] NAFTAL Card : service de carte prépayée pour carburant et services associés. https://naftalcard.naftal.dz/

[7] OpenRouter : plateforme facilitant l'accès aux modèles d'intelligence artificielle. https://openrouter.ai/

[8] Cerebras Systems : entreprise spécialisée dans le développement de processeurs dédiés à l'IA. https://www.cerebras.ai/

[9] Groq : société proposant des solutions matérielles pour l'accélération de modèles IA. https://groq.com/

[10] Together AI : fournisseur de modèles et d'infrastructures d'intelligence artificielle. https://www.together.ai/

[11] Oscaro : site de vente en ligne de pièces automobiles. https://www.oscaro.com/

[12] NVIDIA AI – Llama 3.3 : documentation officielle. https://build.nvidia.com/...

[13] Together AI :`meta/llama-3.3-70B-instruct-turbo` https://www.together.ai/...

[14] Vals.ai – version hébergée du modèle `meta/llama-3.3-70B-instruct-turbo` https://www.vals.ai/...

[15] Article explicatif sur la similarité cosinus. https://studymachinelearning.com/...

[16] Google PageSpeed Insights : outil d'évaluation des performances des applications web. https://pagespeed.web.dev/...